方法学：让自动化系统的数字可信

> 2026-11-01 至 2026-11-04 的四天里，H3D 全部改动都不是"加功能"，而是让已经到了1.1.13 版本、测试全绿、报表齐全的系统不再输出似是而非的数字。本文把这些天里被真机数据推翻的判断逐条记下来，作为论文「方法」与「讨论」两章的素材。文中每个数字都来自 docs/adr/ 与 CHANGELOG 的记录，可复查。

1 问题的性质

自动化建模系统的危险不在于"跑不起来"——跑不起来会立刻被发现。危险在于跑起来了、报表齐全、数字看着合理，但数字与事实无关。

本文记录的九个案例都属于后者，且有一个共同特征：错的那一版比对的更容易让人相信。

前五例（2.1–2.5）来自第一程：判据、单位、约定层面的错。后四例（2.6–2.9）来自第二程，性质略有不同——代码逻辑都是对的，错在"谁来说"和"什么时候说"：来源靠猜、数字不定种子、结论说在决策点之后、单指标被读反。

2 九种失效模式（均有真机证据）

2.1 自报指标与事实不符

align_points_to_mesh 返回的 rmse_after = 0.0968 看着漂亮，实际把几何推离了50 倍（中位距离 0.036 → 1.917）。原因是这个残差：①只统计 p90×2 以内的对应（本身被截断）；②算的是变换前的距离（滞后一步）；③无法区分"收敛到正确答案"与"两边一起漂到一个自洽的错误位置"。

纪律：自报指标不能作为验收依据，必须有外部可核对的量。

2.2 单位与坐标系约定错

- X2 的色差报 ΔE = 21.42：colour.run 要 sRGB 0~1，调用点喂 0~255，全部被钳成纯白。标准值 ×255 落在同一路径上报 21.4193——错得很稳定，误差 0.0007。
- capture_meta.json 存的是原生 COLMAP 格式（R_co + tvec，前方 +Z），管线按「t = 相机中心、前方 −Z」读，等于把 tvec 当成相机位置。

纪律：单位与约定必须由数据本身判定，不能靠"读文档时记得"。后者的判据是用 COLMAP 自己的 points3D.txt 试投：原生解释 30/30 台 95.6%、管线解释 5.25%。

2.3 判据在垃圾数据上触发

这是最隐蔽的一类。位姿读错后，30 台相机里 19 台一条纹素都投不上，剩下 11 台偶然投上，于是 in_frame_fraction 报出 86.7%——「几何已在画幅内，无需对齐」这道闸门正当放行。判据逻辑完全正确，输入是垃圾。

后果是一整串"合理"的数字：coverage 56.81%、岛内填充 87.64%、X3 异常 0.31%/4 处。全部作废。

纪律：任何以 X 为输入的判据，都必须先验证 X 本身可信。位姿类预检尤其如此。

2.4 候选可用性随机

对齐走「控制点优先、失败才回退自动 ICP」。而分支取决于磁盘上有没有文件：一次成功的 ICP 会把控制点导出到 00_ctrl/，下次运行就走控制点那条（实测解出90° 旋转错）。于是同一输入连跑三次，normal_visible = 0.96 / 0.69 / 0.58。

纪律：候选的生成必须是无条件的。判据再好，没有可比对象也等于没有。

2.5 误诊文案把排查引向错误方向

normal_visible_fraction 偏低时，日志断言「网格法线局部方向不一致（常见于碎块化重建）」。实测：相邻面法线反向只有 0.08%，网格法线是全局一致的；真正原因是对齐把几何搬错了位置。

纪律：诊断文案必须能被数据证伪。现在加了 normal_flip_fraction 作为配套判据，文案按它分三支，会直接说出「法线是好的，问题在对齐」。

2.6 「有输入」被当成「有基准」

M5 判「坐标有没有米制语义」只靠一句：

```
metric_units = bool(task.raw_paths)
```

00_raw 里有个文件就被当成有激光基准。于是报表印「激光扫描 / 中误差3.21 mm」，这个数进 5 mm 毫米门，然后被抄进论文。可那个文件完全可能是别的软件照片重建出来的（Metashape / RealityCapture 导出）——坐标是任意单位，那个「mm」不成立。

之前补过两个自证检测（laser_unverified / dual_source_duplicate），但它们都是事后推断：必须同时存在 SfM 稠密模型才判得出。而用户自己知道 00_raw 里放的是什么——界面上却没有地方说。

后果实测（batch3，同一份数据只改一个声明，scripts/probe_data_source.py 可复现）：

声明	中误差列	口径列
auto（默认，按有文件即米制）	87.4019	不判门（单位存疑）
photogrammetry（用户声明照片重建件）	N/A	无量纲（用户声明照片重建件）

注意这里的 87.4019 与 87.42 是两个层次的东西：后者是修复前某一次运行的读数（下一次可能读到 87.01，见 2.7），前者是定种子之后可复现的那个值。同一张表里混用两种口径，正是本文要治的病。

修法不是"加一个开关"，而是把判断权交回用户，同时钉一条硬红线：证据压过声明。声明 laser 而 M1 判出 raw_looks_like_sfm（00_raw 与 SfM稠密近乎重合）时，仍不主张米制，并落 declared_source_conflict + WARN。

纪律：缺省猜测必须能被用户声明覆盖；但声明不能覆盖证据——否则勾一下就能把自证数据包装成米制结果，比没有这个功能更糟。

2.7 数字不可复现：小于 1% 的漂移

同一份输入、同一个分支、连跑三次，M5 的中误差是 86.7811 / 87.4155 / 87.0148。

根因：mesh.sample_points_uniformly(n) 没有 seed 参数（Open3D 0.19 的签名就只有 number_of_points 与 use_triangle_normal），它用进程级随机源。每次重采样到不同的表面点，最近邻距离分布就变。

这个坑 2026-11-03 已经踩过一次（对齐精化的 _REFINE_SEED），当时只修了那一条路径。M5 这条因为「差异 < 1%」被漏掉——而小于 1% 的漂移恰恰是最危险的一档：小到不会触发任何断言，又大到让两天前的报表对不上。

修法不是"在 M5 里也调一下种子"，而是把入口收敛成一个函数：

```
h3d.io.sample_surface(mesh, n, seed) # 「定种子 + 采样」绑死，没法只做一半
```

修后 auto 与 laser 两个等价分支逐字相同（87.4019），跨进程重跑也相同。

一天后再扫源码，还剩四处「先定种子、后自己采样」的两语句形式。其中alignment_quality 里那行种子调用是空的——那里用的是 np.linspace 索引抽样，根本不碰 Open3D 随机源，换多少次种子结果一字不差。它让读者以为「这段依赖随机采样，别动种子」。

纪律：不可复现的数值不能作为结论。「看起来有约束、实际没有」比缺失更糟——下一个人会为了保护一个不存在的约束而绕路。

2.8 时序错位：说清楚了，但说晚了

00_raw/<件>/ 只有一份点云时，M2 走单站直通（恒等落盘、十几毫秒），日志写「M2 完成」，界面灯变绿。用户的结论是「配准成功」——而 FPFH + RANSAC + ICP一次都没跑过。

报表侧早就写清了这件事（identity + identity_reason=single_scan →「配准节点在本件没有被执行过」）。但那是跑完之后才读得到的东西；人是在开跑前形成印象的，很少有人会回头翻报表去推翻自己刚才的印象。

单站本身不是缺陷：中小型文物常只有一站扫描（真机 relic_001 与 batch3 三件全部是 1 份几何）。要修的只是「没说」，所以措辞落在「这是正常终态，但精度不能由本件背书」，不是「出错」。

纪律：结论要在决策点之前说。事后文档再完整，也替代不了事前一句提示。

2.9 单一指标会被读反

报表里的 multiview_color_std（多视角色差）看起来是个"越小越好"的质量指标：

情况		实际
10 台相机，色调一致	小	真·多视图融合，稳
1 台相机硬投影	恒等于 0	没有任何冗余，接缝/漏色无从缓解

两种情况的色差都是"小"，意义完全相反——最该报警的情况恰好是这个指标最漂亮的情况。而能配对的那个量（纹理重叠度）在设计书 §17.3 里写着，代码里一直是"overlap": None，挂了几个版本。

补上之后真机（D:/h3d_relic_test，30 张照片 / 11 台可用）才读得出真问题：

指标	值
texture_overlap	5.77 台/纹素
texture_multi_view_ratio	98.4%
multiview_color_std	40.44

重叠度很高（98.4% 的纹素有冗余），色差照样 40.44 —— 说明不是"看不到"，而是这11 台相机之间色调差得太多。只看色差会去调融合权重；加上重叠度就知道根子是可用相机太少（19 台位姿无效，2.2 节的老账）。

纪律：任何"越大越好 / 越小越好"的单指标，都要有一个反向情形同样满足它的配对量，并且两个数必须一起出现在报表上。

3 六条判据纪律

1. 外部可核对量优先于自报量。 包围盒对角线比、源→目标单向中位距离、COLMAP 稀疏点的可投射性、纹理图集的着色率——这些都不依赖被测组件自己的说法。
2. 判据要能区分"像"与"对"。 in_frame_fraction 只判「投影落在画幅矩形内」，不判「落在文物上」，因此它区分不了 0° 与 90° 的旋转误差（两者都报 1.0）。能区分的是「对齐后有多少面能被相机正面看到」：0.98 vs 0.69。
3. 多候选 + 显式判据 > 单候选 + 事后闸门。 闸门只能拦"离谱"，拦不住"看着合理但错"。三天里三次撞上同一模式：0.43 倍尺度、90° 旋转、精化阶段 0.52 的塌陷——每一个都通过了当时所有的闸门。
4. 先量再改，对照实验不可省。 第一程五次"先量"，其中四次推翻了我自己之前的判断（见第 5 节）。有一次没量就动手（填岛内空洞），做完对目标贡献为 0。
5. 指标要配对读。 见 2.9：multiview_color_std 小既可能是"融合得稳"，也可能是"只有一台相机在看"。凡是"越大越好/越小越好"的单指标，都必须有一个反向情形同样满足它的配对量，且两个数一起进报表。同类还有：coverage_ratio 与island_fill_ratio（后者高而前者低 = 岛划分碎）、rmse_mm 与 rmse_reliable（后者 False 时前者的毫米数没参与判门）。
6. 同一个判定只许有一处实现。 本项目六类"副本"全部漂过：阶段清单（八份）、阶段目录名（登记表之外散落 147 处）、accuracy.csv 列名（表头与核验器各一份）、版本号（三处）、测试夹具（自己写一份假的）、口径文字（quality.run 与 build_report 各写一遍）、采样入口（四处直调）。

而漂移方向不是随机的：总是往「该报的不报」「数字好看」那边漂。

阶段清单少一个 X3 → 完成率分母少一个而不报错；口径文字漏一档 → 报表把"用户

声明"写成"系统推断"；采样漏一处种子 → 数字悄悄变一点点。

纪律的落点是守卫测试，不是文档：tests/test_stage_dirs_single_source.py、

tests/test_sampling_single_source.py、tests/test_version_single_source.py。

写在 ADR 里的纪律只约束写 ADR 的那个人；守卫约束所有人——包括三个月后的自己。

4 一次典型的错误链条

以「M4 覆盖率只有 21%」为例，它被三层误判套住：

```
位姿读错（19/30 台投空）
  └─ in_frame 报 86.7% → 「已在画幅内，跳过对齐」
      └─ 覆盖率 21% 被归因为「采集不足 / 法线问题」
          └─ 修法选错（去查法线、去填洞）
```

修正第一环（位姿约定）之后，后面三环自动消解：对齐成为必需且可解，normal_visible 0.72 → 0.96，覆盖率 0.5865。

上游一个约定错误的传播成本，远高于它本身。

5 八次"先量后推翻"

#	我原本的判断	实测结果	处置
1	X1 的 177 mm 是尺度问题	合成已知形变标定线性度 1.000，尺子一直对；根因是两源混为一期（互最近邻中位 5541 mm）	加两期同源闸门
2	岛间色调跳变 = 缺色卡	19 台相机根本没投上、11 台又是错位姿；修正后 color_std 32.67 → 14.42	归因改为「先保证位姿，再谈光度」
3	减少 UV 岛数能降 X3 噪声	调 xatlas 参数岛数只动 ±15%；把网格做粗岛数 −69% 但 X3 差 4 倍	不改（ADR-0015）
4	X3 图斑是 UV 岛边界伪影	图斑在岛边界上的富集 0.8×（反富集），0 处落在碎岛	假设排除（ADR-0016）
5	填岛内空洞能改善 X3	填掉 12 万纹素，X3 数字一模一样	保留功能但明确不是解药
6	报表里的 87.0 mm 是个"精度结论"	同一输入同一分支连跑三次：86.78 / 87.42 / 87.01	入口定种子（ADR-0020）
7	batch3 是有激光基准的米制数据	声明为照片重建件后，中误差列从 86.78 mm 变 N/A——它本来就不该有毫米	声明 + 证据压过声明（ADR-0020）
8	color_std 40.44 说明多视图融合做得差	同件 texture_overlap 5.77、multi_view_ratio 98.4%——融合有充足冗余，根子是可用相机只有 11/30	补重叠度，两数配对读（ADR-0022）

第 6–8 条的共同点：错不在算法，在于我没区分"数字是多少"和"这个数字能不能引用"。

6 修复前后的可比数字（同一件文物、同一套输入）

指标	修复前	修复后	备注
projected_cameras	11 / 30	30 / 30	位姿约定修正
cameras_blind	19 / 30	0 / 30	同上
normal_visible_fraction	0.7188	0.9617	对齐多初值 + 择优
coverage_ratio	0.6332	0.5865	下降是变好：不再靠背面补色
island_fill_ratio	0.9998	0.9207	同上
multiview_color_std	18.81	14.42	30 台相机全部参与
X3 异常面积	0.6874% / 14 处	0.3294% / 7 处	σ 15.65 → 14.78

指标	修复前	修复后	备注
同输入三次运行	0.96 / 0.69 / 0.58	逐位相同	候选无条件生成
M5 同输入三次运行（mm）	86.78 / 87.42 / 87.01	逐位相同（87.4019）	采样入口定种子

注意 coverage_ratio 与 island_fill_ratio 的下降：修复前那 0.9998 是靠「按 -n 补色」堆出来的（把看不见的地方也用反法线填上颜色），修复后要求真有相机能看到。数字变低而质量变高，是这类系统里最常见的修复形态。

7 可写进论文的五条

1. "测试绿"不构成交付依据。 缺陷存在期间，1200–1400 项单元测试始终全绿——因为它们测的是"函数按我理解的方式工作"，而错误发生在"我的理解"这一层。第二程的四类缺陷（2.6–2.9）更是如此：它们的共同点是代码逻辑正确、语义错位，测试再密也测不出来，只有把两次运行的数字逐字比、或者把同一份数据换个声明再看一遍，才会浮出来。
2. 口径必须写成可复查的断言，而不是注释。 例如 rmse_scope 三态、units_plausible、pose_convention、metric_units_reason——它们让"这个数字能不能引用"成为机器可判的事实，而不是读者的判断。
3. 误诊的成本高于没有诊断。 一条断言"法线不一致"的日志，让我按错误方向查了一整轮。现在这条日志会先说"法线是好的（反向 0.00%）"，再指向对齐。
4. 判断权交回用户，但证据压过声明。 系统不可能知道 00_raw 里放的是什么，所以来源必须可声明；但声明一旦能覆盖证据，它就成了绕过检查的后门。这条张力在 2.6 里表现为一个具体开关，在更一般的系统里表现为"人机分工"。
5. 纪律的载体是守卫测试，不是文档。 写在 ADR 里的纪律只约束写 ADR 的那个人。本项目把四条纪律变成了可执行的守卫（阶段目录名、版本号、采样入口、报表列名），其中采样那条在加守卫的当天就抓出四处残留——包括一处"看起来有约束、实际没有"的空种子调用。人眼扫过的那几遍都没看见它。

附：可复查入口

内容	位置
位姿约定	docs/adr/0013-capture-meta-pose-convention.md
对齐多初值与尺度	docs/adr/0014-icp-multistart-and-scale-clamp.md
UV 岛数（不做）	docs/adr/0015-uv-island-count-is-mesh-bound.md
X3 图斑成因	docs/adr/0016-x3-anomaly-provenance.md
光度校准上限	docs/adr/0012-photometric-calibration-ceiling.md
交付核验（23 项）	docs/adr/0017-delivery-verification.md
布局迁移必须搬账	docs/adr/0018-layout-migration-must-move-the-books.md
数据来源声明 + 采样定种子	docs/adr/0020-data-source-declaration-and-sampling-seed.md
单站直通要在开跑前说	docs/adr/0021-single-station-says-so-before-you-run.md
纹理重叠度（指标配对读）	docs/adr/0022-texture-overlap-metric.md
采样入口只能有一个	docs/adr/0023-sampling-has-exactly-one-entry.md
复现脚本	scripts/probe_uv_charts.py、probe_poisson_params.py、probe_depth_chain.py、probe_x3_provenance.py、probe_data_source.py
守卫测试	tests/test_stage_dirs_single_source.py、test_sampling_single_source.py、test_version_single_source.py
交付核验命令	h3d verify <项目根>（23 项，退出码 0=通过）