采集与标注规范：病害语义（S0 / X3）

配套文档：docs/采集规范-色卡与ArUco.md（先满足那份，再满足这份）。

本文的每一条约束都对应 scripts/check_damage_labels.py 里的一条检查——

写在这里却没人执行的规定等于没有。

0 这份规范解决什么问题

S0 病害语义一直开不了，不是因为代码，而是因为没有可学的病害实例：现有候选区全是「UV 岛边界 / 材质交界」，残存彩绘只占 1.89%，硬标只能分出「彩绘 / 胎体」——那是域分类，不是病害。

本文定义：拍什么、怎么拍、怎么命名、标成什么格式，以及拍完怎么自检。拍齐 + 自检过，才能开工。

1 前置条件（不满足就别开始）

#	条件	为什么
1	一件病害形态明确的文物	裂隙/起翘/脱落/泛碱，肉眼能指着说"这就是"
2	同一批照片跑得通 S1（COLMAP）	语义要复用 M4 的位姿做多视图票决，位姿错了一切白搭
3	色卡与本规范的照片在同一次采集内	ΔE 类判据要色卡；两次采集的光照不可比
4	至少 3 类病害，每类 ≥ 10 处实例	低于这个量只能做 few-shot 演示，做不了评估

2 目录与命名

```
<项目根>/
  阶段成果/00_photo/<item>/ IMG_0001.JPG …  （原有，不改名）
  阶段成果/90_meta/<item>_capture_meta.json  （S1 产物）
  damage/<item>/
      labels.json ← 本规范定义的标注文件（一件一个）
      overview.md ← 可选：现场笔记、裂缝草图标号

<标注包根>/（可选，独立于项目也行）
  <item>/labels.json
```

约定

- 一件文物一个 labels.json，不按病害拆文件——拆开就必须靠目录名维系一致性。
- 照片文件名保持相机原始名，不要为了标注改名：capture_meta.json 里记的是原名，改名等于让位姿对不上。
- 病害 id 形如 D001、D002（三位，从 001 起，只增不改：删掉的 id 不回收，否则历史报表与标注包对不上）。

3 每处病害拍几张、怎么站位

要求	数值	理由
同一处病害的有效视角数	≥ 3（推荐 5）	少于 3 时多视图票决退化成单视图硬投影——那个坑的记录是「整件都判成有病害」

要求	数值	理由
视角之间的最大夹角	≥ 40°	同一机位连拍三张不算三个视角（脚本会算，不靠自觉）
相机到病害的法向夹角	每张 ≤ 60°（cos>0.5）	斜视太厉害的掩膜边界不可信
相邻视角重叠	≥ 60%（以病害为中心看）	票决要能对上同一纹素
病害在画面里占比	≥ 1/8 短边	太小的话 pixel_scale 换算后不足 10 个纹素

站位提示：把病害放在画面中央，绕它走小弧（像拍人脸特写），别站在一个点变焦。深腔/内侧病害必须补低机位或俯拍——俯拍补不到的东西，后面谁也算不出来。

4 标注文件格式（labels.json）

```
{
  "schema": "h3d-damage-labels/1",
  "item_id": "relic_002",
  "captured_at": "2026-11-07",
  "operators": ["张三"],
  "classes": ["crack", "detachment", "efflorescence"],
  "damages": [
    {
      "id": "D001",
      "class": "crack",
      "note": "口沿纵向裂隙，长约 3 cm",
      "views": [
        {"photo": "IMG_0012.JPG", "polygon": [[812, 455], [830, 461], [826, 610]], "difficulty": "clear"},
        {"photo": "IMG_0013.JPG", "polygon": [[540, 470], [556, 478], [551, 602]], "difficulty": "clear"},
        {"photo": "IMG_0018.JPG", "polygon": [[300, 520], [318, 525], [315, 640]], "difficulty": "unclear"}
      ]
    }
  ]
}
```

字段

字段	必填	说明
schema	√	固定 h3d-damage-labels/1；不认识的版本直接拒
item_id	√	必须等于所在目录名（脚本会核）
classes	√	出现过的类别，取自 §5 的白名单
damages[].id	√	D + 三位数字，唯一
damages[].class	√	白名单里的英文键
damages[].views[]	√	≥3 条
views[].photo	√	原图文件名（与 00_photo/<item>/ 一致）
views[].polygon	√	原图像素坐标的多边形，≥3 点，闭合不必重复首点
views[].difficulty	—	clear / unclear；统计时把 unclear 单列，别混进主指标

为什么用多边形而不是掩膜 PNG：多边形可读、可复核、可 diff，出错误一眼看得出；掩膜 PNG 只能靠肉眼看图，十处以上就没法查了。管线读入后再栅格化，成本可忽略。

5 类别白名单（只收这四类）

key	中文	判读要点	不收的情形
crack	裂隙	线状、有深度阴影、跨材质连续	表面划痕、彩绘笔触、器形棱线
detachment	起翘 / 脱落	边缘有隆起或缺失，露出下层	单纯的颜色变浅（那是变色）
efflorescence	泛碱 / 盐析	白色粉状或结壳，多在水线/接缝	高光、灰尘、补配材料
loss	缺失（结构性）	整块形体缺失，边界锐利	局部剥落小块（归 detachment）

歧义处理：拿不准的不标，或在 note 里写「存疑」。宁可少 2 处，不要把「不确定」混进训练集——那等于教模型学噪声。

6 拍完自检（必跑，30 秒）

.venv_lab\Scripts\python.exe scripts\check_damage_labels.py <标注包根> --project <项目根>

脚本会核（每条都对应上面某一节）：

检查	不过的后果
labels.json 版本 / 必填字段	拒绝加载
item_id 与目录名一致	拒绝加载
每处病害视角数 ≥3	该处标记为不足，不进训练集
视角最大夹角 ≥40°	该处标记为同机位（等于只有一个视角）
每张 view 的照片存在、多边形在画幅内	硬失败
每张 view 在 capture_meta 里有位姿	硬失败（否则反投影做不了）
每类 ≥10 处、≥3 类	报告「样本不足」，给差距数

7 验收判据（能不能开工，看这张表）

判据	门槛	不达标怎么办
有效病害处数（视角足 + 有全部位姿）	≥30	再拍
类别数	≥3	补拍缺的类别
每类处数	≥10	补拍该类
照片能跑通 S1（30/30 台可用）	是	回 采集规范-色卡与ArUco.md §3 查光照/重叠

四项全过 → 可以开 S0。任何一项不过 → 开出来的模型只能做演示，不能写进论文。

8 与管线的对应关系

阶段	读什么	做什么
M4	00_photo + capture_meta	位姿 / pixel_scale / Z-buffer（已有）
X3 无监督	图集 + 掩膜	出「待复核处数」（已有，不是病害类别）
X3 语义（待做）	labels.json + M4 位姿	多边形 → 反投影 → 逐纹素加权票决 → UV 类别图 → 按纹素积分 3D 面积

目前 damage/ 不进 阶段成果/：标注是外部输入（和 00_photo 同级），先把数据跑通再决定要不要并进 paths.STAGE_DIRS——并入要动目录清单与核验器（23 项），在一条真实标注都没有之前不值得。

9 已知限制

- 本规范只管单期（一次采集）。时序追踪（X4）要两期，另议。
- 类别白名单刻意只收 4 类：类越多每类样本越薄，30 处撑不起 6 类。
- 多边形标注在原图坐标，与 photos_small（2400 长边）不同——管线读入时按pixel_scale 换算，不要手工缩放后存进去（那个坑的记录：直索引导致颜色全取左上角 53% 且无报错）。